

Analisei

1 MILHÃO

**de acidentes em rodovias
federais**

Peguei dados públicos da ANTT e construí um pipeline
end-to-end do zero. Veja a arquitetura completa. 🚦

Dados públicos da ANTT, do bruto ao dashboard

Um pipeline end-to-end construído do zero a partir de arquivos abertos de acidentes em rodovias federais concedidas.

35

concessionárias integradas

2007–2025

18 anos de histórico

Medallion no Fabric

Três camadas, um único OneLake. Cada estágio refina os dados da camada anterior.



Bronze

Ingestão dos arquivos brutos da ANTT



Prata

Limpeza e padronização com PySpark



Ouro

Modelo analítico em Constellation Schema

Dados brutos, sem transformação

Ingestão dos arquivos da ANTT exatamente como vieram. Tudo cai no **OneLake** — nenhuma modificação, total rastreabilidade da origem.

```
raw/ antt_acidentes_2007.csv  
raw/ antt_acidentes_2008.csv  
... # sem schema, sem limpeza
```



Limpeza, padronização e enriquecimento

01 Padronização de datas e formatos

02 Remoção de duplicatas

03 Enriquecimento com dados das concessionárias

Modelo analítico pronto para o BI

Aqui os dados viram um modelo dimensional. A escolha foi um **Constellation Schema** — e não um Star Schema.

A PERGUNTA-CHAVE

Por que Constellation e não Star Schema?

→

Dois processos, dimensões compartilhadas

O dataset tem **acidentes** e **trechos rodoviários**. Forçar tudo num Star Schema criaria uma fact table enorme e redundante.



40%

mais rápido nas consultas, reutilizando dimensões e mantendo as facts separadas.

Modo Direct Lake

O relatório lê direto do **Delta Lake no OneLake**. Sem import, sem scheduled refresh.

Sempre atualizado

Os dados refletem o lakehouse em tempo real.

Zero duplicação

Sem custo de armazenamento copiado.

0 resultado em escala

1M+

registros processados

35

concessionárias integradas

18

anos de histórico (2007–2025)

99,5%

de SLA do pipeline

Antes eu juntava 4 serviços. Agora é um só.

ANTES

ADF + ADLS + Databricks

Power BI separado

Permissões entre cada serviço

COM FABRIC

Mesmo workspace

Mesmo OneLake

Mesma governança

-70% no tempo de setup do ambiente.



Se você trabalha com dados e ainda não explorou o Fabric, esse projeto é um bom ponto de partida.

Um workspace, um lakehouse e uma governança única — do arquivo bruto ao dashboard.

 OPEN SOURCE

Código 100% público

Com README detalhado e diagrama da arquitetura. [O link está nos comentários.](#)

★ Salve este post

↻ Compartilhe

adrianogvs.com.br

#MicrosoftFabric #DataEngineering #PySpark #DeltaLake #PowerBI
#MedallionArchitecture #DataLakehouse #Azure #Analytics